

> NIH Chest X-ray14: Detección de Patologías

1. Objetivo del Proyecto

El objetivo de este trabajo es entrenar un modelo de red neuronal convolucional (CNN) para realizar clasificación multietiqueta de imágenes de rayos X de tórax, identificando enfermedades como Pneumonia y Emphysema, entre otras, utilizando el dataset NIH Chest X-ray14.

2. Dataset Utilizado

Fuente: NIH Chest X-ray14

Total de imágenes disponibles (tras procesado): ~112,000

Formato: PNG

Etiquetas: Multiclase (cada imagen puede tener una o más enfermedades)

Etiquetas incluidas: Las principales clases extraídas fueron ['Atelectasis', 'Cardiomegaly', 'Effusion', 'Emphysema', 'Infiltration', 'Mass', 'Nodule', 'Pneumonia', 'Pneumothorax'].

3. Preprocesamiento de Datos

Se cargan los archivos .csv con etiquetas y se asocian a las imágenes correspondientes ubicadas en múltiples subdirectorios.

Se transforman las etiquetas multiclase de texto a formato binarizado con MultiLabelBinarizer().

Se descartan imágenes sin correspondencia en disco.

Se aplica un split estratificado:

- Entrenamiento: 72%
- Validación: 8%
- Test: 20%

4. Preprocesamiento de Imágenes

Tamaño de entrada: (224, 224, 3)

Normalización: Reescalado a rango [0,1]

Aumentación: (solo en entrenamiento)

Se aplicaron también: rotación, zoom, desplazamientos horizontales y verticales, y flip horizontal.

5. Arquitectura del Modelo

Modelo CNN secuencial compuesto por:

| Capa | Detalles |
|------------------|--|
| Conv2D (32) | Kernel 3x3, activación ReLU |
| MaxPooling2D | Tamaño 2x2 |
| Conv2D (64) | Kernel 3x3, activación ReLU |
| MaxPooling2D | Tamaño 2x2 |
| Conv2D (128) | Kernel 3x3, activación ReLU |
| MaxPooling2D | Tamaño 2x2 |
| Flatten | Aplanamiento del volumen |
| Dense (128) | Activación ReLU + Dropout 0.5 |
| Dense (n_clases) | Activación Sigmoid (salida multilabel) |

6. Compilación y Entrenamiento

Optimización: Adam (lr=0.0001)

Función de pérdida: binary_crossentropy (adecuada para multilabel)

Métrica principal: AUC (Área Bajo la Curva ROC)

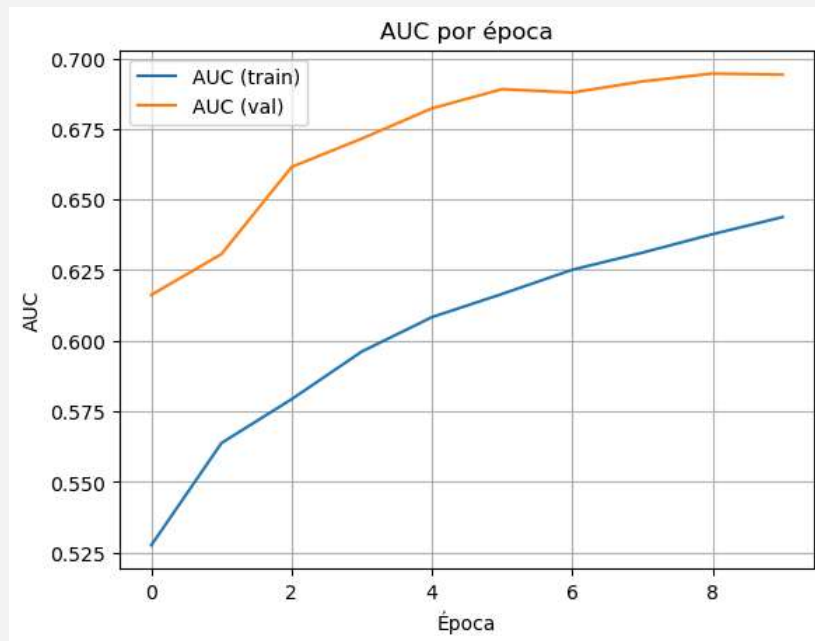
Épocas: 10

Tamaño de batch: 64

Callbacks: ModelCheckpoint (guarda el mejor modelo por val_loss)

7. Resultados del Entrenamiento

Tras establecer la resolución de entrada en 224x224, se observó una mejora sustancial en la capacidad del modelo para aprender. La curva de AUC muestra una progresión estable, con la AUC de validación alcanzando valores cercanos a 0.70, lo cual indica que el modelo logra capturar patrones diagnósticos útiles en las imágenes.



8. Evaluación Visual

Se visualizó un subconjunto de imágenes de test con sus clases reales y predichas. Se aplicó un umbral de 0.5 para considerar una clase como presente. Cada imagen muestra:

- True: Clases reales según anotaciones
- Pred: Clases estimadas por el modelo

Esto permite verificar si el modelo identifica correctamente múltiples patologías por imagen.

9. Conclusión y Observaciones

Finalmente, se ha visto que el modelo puede detectar múltiples enfermedades en imágenes de rayos X con un enfoque de aprendizaje supervisado multilabel. El tamaño de imagen inicial (32x32) limitó la capacidad del modelo para capturar detalles médicos sutiles. Al utilizar un tamaño de 224x224 se produjo un impacto positivo claro en el rendimiento del modelo. Se redujo el gap entre entrenamiento y validación, lo cual sugiere que el modelo ahora está menos limitado por la capacidad de entrada. Aun así, el modelo no muestra síntomas fuertes de sobreajuste, por lo que aún puede beneficiarse de un mayor número de épocas o de una arquitectura más profunda. La métrica AUC es adecuada para evaluar modelos multilabel, especialmente cuando las clases están desbalanceadas. Finalmente, las curvas de validación vs. entrenamiento no muestran signos fuertes de overfitting, lo cual es positivo.